

Analisis Spam Filtering untuk Short Message Service (SMS) dengan Metode Naïve Bayes

Mona Ulyasari^{*1}, Aulia Putri Rahmawati², Fadhila Eka Giovani³, Laura Oktaviani Putri⁴, Nida Ruhana Zakiyya⁵, Nadya Alfirayna⁶, dan Dania Siregar⁷

¹ Universitas Negeri Jakarta, Jakarta Timur, Indonesia

² Universitas Negeri Jakarta, Jakarta Timur, Indonesia

³ Universitas Negeri Jakarta, Jakarta Timur, Indonesia

⁴ Universitas Negeri Jakarta, Jakarta Timur, Indonesia

⁵ Universitas Negeri Jakarta, Jakarta Timur, Indonesia

⁶ Universitas Negeri Jakarta, Jakarta Timur, Indonesia

⁷ Universitas Negeri Jakarta, Jakarta Timur, Indonesia

Jl. Rawamangun Muka Raya No.11, Rawamangun, Kec. Pulo Gadung, Kota Jakarta Timur, Daerah Khusus Ibukota Jakarta 13220

*Korespondensi: mona_1314622003@mhs.unj.ac.id (11 pt, italic)

Diajukan: 27-12-2024; **Direvisi:** tgl-bln-thn; **Diterima:** tgl-bln-thn

Abstract

This study aims to implement text mining using the Naïve Bayes algorithm for spam filtering in Short Message Service (SMS) messages. The dataset comprises 1,000 Indonesian SMS entries collected by the researchers and manually classified into spam and ham messages. The analysis process includes data preprocessing steps such as cleaning, case folding, tokenizing, stopword removal, and stemming, followed by Term Frequency-Inverse Document Frequency (TF-IDF) weighting to enhance classification accuracy. The Multinomial Naïve Bayes algorithm was applied to classify the data into spam or ham categories, with evaluation conducted using a confusion matrix, classification report, and accuracy score. The results show that the Naïve Bayes model achieved an accuracy of 96%, with high precision and recall, demonstrating its reliable performance in distinguishing spam from ham messages. TF-IDF weighting effectively highlighted relevant words for classification. This study confirms that text mining using the Naïve Bayes algorithm has been successfully implemented for spam filtering in SMS messages.

Keywords: Spam filtering; Short Message Service (SMS); Text Mining; Naive Bayes; TF-IDF

Abstrak

Penelitian ini bertujuan untuk mengimplementasikan *text mining* berbasis algoritma Naïve Bayes dalam melakukan *spam filtering* pada pesan *Short Message Service* (SMS). Data yang digunakan berupa 1000 data SMS berbahasa Indonesia milik peneliti yang diklasifikasikan secara manual menjadi pesan spam dan ham. Proses analisis meliputi tahapan *preprocessing data* seperti *cleaning*, *case folding*, *tokenizing*, *stopword removal*, dan *stemming*, yang diikuti oleh pembobotan Term Frequency-Inverse Document Frequency (TF-IDF) untuk meningkatkan akurasi klasifikasi. Algoritma Multinomial Naïve Bayes diterapkan untuk mengklasifikasikan data menjadi pesan spam atau ham, dengan evaluasi menggunakan *confusion matrix*, *classification report*, dan *accuracy score*. Hasil penelitian menunjukkan bahwa model Naïve Bayes berhasil mencapai akurasi sebesar 96%, dengan *precision* dan *recall* yang tinggi, yang mencerminkan kinerja model yang andal dalam membedakan pesan spam dan ham. Pembobotan TF-IDF terbukti efektif dalam menyoroti kata-kata yang relevan untuk klasifikasi. Penelitian ini mengonfirmasi bahwa *text mining* berbasis algoritma Naïve Bayes telah berhasil diterapkan untuk *spam filtering* pada pesan SMS.

Kata Kunci: Spam filtering; Short Message Service (SMS); Text Mining; Naive Bayes; TF-IDF

Pendahuluan

Perkembangan teknologi di bidang komunikasi semakin mempermudah proses pertukaran informasi dimana pun dan kapan pun. Dewasa ini, banyak media komunikasi terkini yang dapat digunakan untuk berbagi pesan singkat, seperti WhatsApp, Line, dan Telegram. Namun, salah satu media lawas yang hingga saat ini masih digunakan secara luas adalah *Short Message Service* (SMS). Meskipun sudah terbilang jarang, SMS dapat dikatakan sebagai media komunikasi penting yang masih krusial hingga saat ini. Hal ini terbukti dari masih banyaknya proses registrasi *online* yang mengharuskan pengguna melakukan verifikasi melalui SMS. Selain itu, Wahid et al. (2021) menyebutkan bahwa SMS menggunakan tipe data *asynchronous messages* yaitu pengiriman data dengan mekanisme *store* dan *forward* yang membuat pengirim dan penerima pesan tidak perlu *online* secara bersamaan. Dengan demikian, dapat dikatakan bahwa SMS masih digunakan dan dipercaya sebagai media komunikasi yang dinilai aman dan mudah digunakan.

Tanpa bisa dipungkiri, segala dampak positif yang diberikan oleh SMS juga dibarengi oleh dampak negatif. Berkembangnya teknologi memungkinkan dilakukannya penyalahgunaan SMS oleh pengguna yang tidak bertanggungjawab. Penyalahgunaan ini dapat berupa pengiriman pesan-pesan tidak bermanfaat yang tidak diinginkan pengguna hingga tindak kejahatan digital seperti penipuan, yang bisa disebut sebagai SMS spam. Munitasari et al. (2018), seperti yang dikutip dalam Wahid et al. (2021), menjelaskan bahwa SMS spam seringkali berisi penawaran layanan iklan, tawaran jasa, hingga promosi dan diskon toko yang mengatas namakan provider tertentu. SMS yang masih sering dijadikan media verifikasi menggunakan kode OTP (*One-Time Password*) juga dapat mengancam keamanan pengguna apabila terjadi penyalahgunaan seperti pengiriman kode OTP palsu. Hal ini membuat SMS *spam* tidak hanya mengganggu pengguna mengenai pesan yang tidak diinginkan, tetapi juga dapat sangat merugikan pengguna.

Selain itu, SMS *spam* juga dapat menjadi pintu masuk bagi serangan *cyber* yang lebih serius, seperti *phishing*. Berdasarkan Laporan Lanskap Keamanan Siber Indonesia tahun 2023 oleh ID-SIRTII, *cybercrime* dalam bentuk PhishingSite di Indonesia sendiri mencapai 47.231.390 kasus, tertinggi kedua setelah Generic Trojan RAT. Praktek *cybercrime* Phising melalui SMS, atau yang dikenal dengan istilah *smishing* (SMS *phishing*), memanfaatkan trik manipulasi psikologis untuk membuat korban memberikan informasi pribadi atau data sensitif, seperti nomor kartu kredit, kata sandi, atau informasi akun lainnya. Pesan-pesan ini sering kali terlihat meyakinkan dan seolah-olah berasal dari lembaga resmi, seperti bank atau institusi pemerintahan.

Penelitian oleh Sofyan et al. (2024) bertujuan untuk mengembangkan model klasifikasi untuk membedakan antara SMS *spam* dan SMS normal. Penelitian ini menggunakan algoritma *Support Vector Machine* (SVM) serta menerapkan metode CRISP-DM (*Cross Industry Standard Process for Data Mining*) untuk mengembangkan model kemudian diimplementasikan kedalam Aplikasi Deteksi SMS Spam berbasis *Streamlit*. Penelitian ini menemukan bahwa algoritma SVM dapat mengklasifikasikan SMS *spam* berbahasa Indonesia dengan baik dengan tingkat *accuracy* model sebesar 96,94%. Selain itu, penelitian yang membandingkan algoritma Naïve Bayes dengan *Support Vector Machine* (SVM) dalam klasifikasi SMS *spam* berbahasa Indonesia oleh Widyawati et al. (2019) mengungkapkan bahwa performa pemodelan Naïve Bayes mengungguli SVM dalam hal *recall* (penentuan seberapa baik model mengenali semua contoh yang relevan) sebesar 94% dan *precision* (evaluasi kebenaran prediksi positif) sebesar 95%. Penelitian ini juga menyimpulkan bahwa kesalahan klasifikasi awal dari data aktual paling sedikit dilakukan oleh Naïve Bayes, baik menggunakan maupun tanpa tahapan *stopword removal*.

Maraknya penyalahgunaan SMS membuat banyak pihak mengembangkan langkah-langkah untuk melindungi pengguna. Misalnya, operator telah menerapkan filter yang mendeteksi dan memblokir SMS

yang diduga merupakan *spam*. Untuk meningkatkan efektivitas sistem pemfilteran ini, berbagai algoritma dapat digunakan untuk mengklasifikasikan pesan dengan akurat. Salah satu algoritma yang dapat digunakan dan baik dalam pengklasifikasian teks adalah Naïve Bayes (Anggraini et al., 2024). Penelitian ini bertujuan untuk melakukan *spam* filtering untuk *Short Message Service* (SMS) berdasarkan metode Naïve Bayes. Penelitian ini dimaksudkan untuk mendeteksi dan menyeleksi pesan-pesan SMS yang merupakan pesan *spam* sehingga diharapkan dapat menjaga dan meningkatkan keamanan pengguna SMS.

Tinjauan Pustaka Spam Filtering

M. A. dan R. A. Ramadhan (2018), seperti yang dikutip dalam Sofyan et al. (2021) mengatakan bahwa pesan *spam* merupakan pesan elektronik yang tidak diinginkan oleh penerima pesan atau dengan kata lain merupakan pesan yang dikirim tanpa persetujuan yang sah dari penerima. Pesan *spam* umumnya beragam, mulai dari penawaran layanan iklan, promosi, hingga penipuan. Pesan *spam* dapat melanggar privasi dengan memanfaatkan data pribadi tanpa izin dan memiliki potensi untuk menimbulkan kerugian apabila digunakan oleh oknum-oknum yang tidak bertanggung jawab. Untuk mengurangi kerugian akibat dari penyalahgunaan pengiriman pesan ini, salah satu pendekatan yang bisa dilakukan adalah dengan cara melakukan penyaringan atau *filtering* terhadap pesan *spam*.

Spam filtering atau penyaringan *spam* dapat dikatakan sebagai proses identifikasi pesan yang dianggap sebagai pesan *spam* sehingga pesan tersebut tidak masuk ke dalam kotak masuk pengguna. Salah satu *filter* untuk mengatasi pesan *spam* adalah klasifikasi. Kurniawan et. al. (2012), seperti yang dikutip dalam Wibisono et al. (2020) mengatakan bahwa dengan adanya klasifikasi, pesan *spam* dan bukan *spam* (ham) dapat dipisahkan sehingga akan sangat membantu pengguna agar hanya mendapatkan pesan-pesan yang diinginkan.

Naïve Bayes

Menurut teori probabilitas statistika, Naïve Bayes merupakan teorema dengan dua penafsiran berbeda. Dalam penafsiran Bayes, teorema ini menyatakan seberapa jauh derajat kepercayaan harus berubah secara rasional ketika ada petunjuk baru. Sementara dalam penafsiran frekuentis, teorema ini menjelaskan representasi invers probabilitas dua kejadian. Teorema Bayes merupakan dasar statistika Bayes dan memiliki penerapan dalam sains, rekayasa, teori permainan, kedokteran, ilmu ekonomi, dan hukum.

Teorema Bayes menggambarkan hubungan antara dua peluang bersyarat dari dua kejadian A dan B sebagai berikut:

$$P(A | B) = \frac{P(B | A)}{P(B)}$$

$$P(A | B) = \frac{P(B | A)P(A)}{P(B | A)P(A) + P(B | A^c)P(A^c)}$$

Naïve Bayes merupakan teknik sederhana untuk membuat klasifikasi, di mana model menetapkan label kelas untuk contoh masalah dan direpresentasikan sebagai vektor dari nilai fitur, di mana label kelas diambil dari beberapa himpunan berhingga.

Naïve Bayes bekerja sangat baik dibanding *model classifier* lainnya. Keuntungan penggunaan metode ini yaitu hanya membutuhkan jumlah data latih (*training data*) yang kecil untuk melakukan estimasi parameter yang dibutuhkan dalam proses pengklasifikasian. Model diasumsikan sebagai variabel independen, sehingga hanya varians dari suatu variabel dalam sebuah kelas yang dibutuhkan untuk menentukan klasifikasi, bukan keseluruhan matriks kovarian.

Short Message Service (SMS) Spam

Menurut Bukola Asaju et al. (2021), *Short Message Service* (SMS) merupakan komunikasi teks *platform* yang digunakan untuk bertukar pesan teks singkat. Pesan-pesan ini biasanya kurang dari 160 karakter tujuh bit. Masalah utama yang dihadapi oleh pengguna ponsel adalah penerimaan pesan SMS yang tidak diminta, seperti yang dikutip dalam Bukola Asaju et al. (2021) bahwa pesan yang tidak diminta dianggap sebagai pesan *spam*. Pesan-pesan *spam* ini biasanya berasal dari pengiklan dan sumber lain. Menurut pandangan Ramdhan et al. (2022), salah satu sumber *spam* umumnya dilakukan oleh situs internet yang menawarkan layanan gratis. SMS *spam* memiliki beberapa jenis pesan, seperti penawaran modal ventura, investasi, promosi, dan penipuan.

SMS spam telah menjadi gangguan besar bagi pengguna ponsel karena sifatnya yang menyebar luas. Hal ini menyebabkan kerugian yang signifikan dalam hal hilangnya produktivitas, peningkatan penggunaan *bandwidth* jaringan, kesulitan dalam manajemen, serta pelanggaran serangan privasi pribadi sebagaimana tertulis dalam Abdulhamid et al. (2017). SMS *spam* tidak hanya mengganggu pengguna, tetapi juga dapat menyebabkan ancaman serius terhadap keamanan data pribadi. Ojugo dan Oyemade (2021) menyatakan dengan jelas bahwa pengguna ponsel memerlukan tingkat privasi tertentu dengan ponsel mereka agar terbebas dari serangan *spam* dan virus. Oleh karena itu, diperlukan langkah penanganan yang efektif untuk mengatasi kasus SMS *spam* mengingat dampaknya terhadap privasi, keamanan, dan kenyamanan pengguna.

Metodologi Penelitian

Data

Data yang digunakan dalam penelitian ini berupa data berformat .csv (*Comma Separated Values*) hasil *crawling* kumpulan SMS berbahasa Indonesia di ponsel peneliti. Setelah diekstrak menggunakan aplikasi berbasis android “SMS Backup & Restore” dan dipilah sedemikian rupa untuk menyederhanakan tabel ketika proses analisis, diperoleh data yang terdiri atas 1000 baris entri dengan 466 pesan ham dan 534 pesan *spam*. File .csv berisi dua kolom, yakni “Label” yang berisi status *spam*/ham dan “Message” yang merupakan isi dari pesan itu sendiri.

Proses identifikasi pesan sebagai SMS *spam* atau non-*spam* (ham) dilakukan secara manual satu per satu dengan memperhatikan beberapa pertimbangan. SMS dikategorikan sebagai *spam* apabila mengandung kata berulang seperti “promo”, “hanya hari ini”, “selamat”, “cek di sini”, dan sebagainya. Sebaliknya, SMS yang dikategorikan sebagai ham adalah pesan berisi kode verifikasi, pemberitahuan langganan paket data/informasi pulsa non promosi dari operator kartu seluler ponsel, pesan dengan pengirim yang dikenali peneliti, atau pesan dari lembaga resmi pemerintahan.

Teknik Analisis Data

Tahapan analisis data untuk melakukan *spam filtering* terdiri dari lima langkah utama, yaitu *input* data, *preprocessing* data, pembobotan menggunakan TF-IDF, klasifikasi dengan algoritma Naïve Bayes, dan evaluasi. Berikut adalah penjelasan rinci mengenai setiap tahapan.

a. Input Data

Input data merupakan tahap awal dalam proses analisis data, data yang diperlukan terlebih dahulu dikumpulkan dan disiapkan untuk proses selanjutnya. Data yang terkumpul akan disimpan dalam format digital yang sesuai, seperti .csv atau .xlsx untuk memudahkan pengolahan data lebih lanjut.

b. Preprocessing Data

Tahapan *preprocessing* data adalah proses untuk membersihkan dan mempersiapkan data mentah sebelum melakukan proses klasifikasi Naïve Bayes. Tahapan ini terdiri dari beberapa langkah sebagai berikut.

1) Cleaning

Cleaning data merupakan proses untuk menghilangkan data *noise*, yaitu menghapus karakter yang tidak perlu/mengganggu dan tidak konsisten. Pada tahap *cleaning*, data yang tidak relevan seperti tanda baca, angka, atau karakter khusus juga dihapus.

2) *Case Folding*

Case folding adalah proses mengubah semua huruf dalam teks menjadi huruf kecil (*lowercase*). Langkah ini memastikan bahwa kata-kata dengan huruf kapital dianggap sama dengan kata-kata yang ditulis tanpa huruf kapital, seperti “Data” dan “data”. Hanya huruf ‘a’ sampai dengan ‘z’ yang diterima. Karakter selain huruf dihilangkan dan dianggap *delimiter* (pembatas) (Triawati, 2009).

3) *Tokenizing*

Tahap *tokenizing* adalah proses memecah atau memotong teks menjadi unit terkecil yang disebut token yang biasa berupa kata-kata atau frasa pendek dengan menggunakan spasi untuk memisahkan antar katanya. Misalnya, kalimat “Saya sedang belajar” akan dipecah menjadi kata “Saya”, “sedang”, dan “belajar”.

4) *Stopword Removal*

Stopword removal adalah langkah menghapus kata-kata umum yang tidak memberikan banyak informasi yang signifikan dalam data, seperti “dan”, “di”, dan “atau”. Penghapusan ini dilakukan untuk mengurangi dimensi data tanpa mengurangi informasi penting. Pada penelitian ini, kami menggunakan *library nltk* (*Natural Language Toolkit*) dan untuk membantu proses ini.

5) *Stemming*

Stemming adalah proses menghapus imbuhan yang melekat dan mengubah kata-kata ke bentuk dasarnya. Sebagai contoh, kata “belajar”, “pelajaran”, dan “belajarliah” akan diubah menjadi “belajar”. Langkah ini bertujuan untuk menyamakan kata-kata yang memiliki akar kata yang sama sehingga lebih mudah dipahami dan dianalisis. Untuk melakukan tahap ini, kami menggunakan *library Sastrawi*, yang merupakan alat untuk pemrosesan bahasa alami dalam bahasa Indonesia.

c. Pembobotan dengan TF-IDF

Term Frequency-Inverse Document Frequency (TF-IDF) adalah metode pembobotan yang digunakan untuk menilai pentingnya sebuah kata dalam suatu dokumen terhadap kumpulan dokumen. *Term Frequency* atau TF mengukur seberapa sering sebuah kata muncul dalam dokumen, sementara *Inverse Document Frequency* atau IDF mengukur seberapa unik kata tersebut dalam seluruh dokumen sehingga kata-kata yang jarang muncul tetapi penting akan memiliki bobot yang lebih tinggi. TF-IDF membantu menonjolkan kata-kata yang relevan dengan dokumen tertentu, tetapi jarang muncul di dokumen lain untuk meningkatkan akurasi analisis.

d. Klasifikasi Naïve Bayes

Naïve Bayes adalah algoritma klasifikasi berbasis probabilitas yang menggunakan Teorema Bayes dengan asumsi independensi antar fitur. Algoritma ini sering digunakan untuk klasifikasi teks karena tergolong sederhana dan efisien. Naïve Bayes cocok untuk menangani data teks karena dapat menangkap hubungan probabilistik antar kata-kata dalam dokumen meskipun dianggap independen. Dalam penelitian ini, klasifikasi Naïve Bayes digunakan untuk mengklasifikasikan data sebagai *spam* atau bukan *spam* (*ham*).

e. Evaluasi

Tahap evaluasi dilakukan untuk mengukur kinerja yang dihasilkan. Dalam penelitian ini, evaluasi disajikan dalam bentuk *confusion matrix*. *Confusion matrix* memberikan informasi dalam bentuk angka-angka yang tersusun dalam matriks berukuran 2×2. Dari *confusion matrix* tersebut, dapat

dihitung nilai-nilai seperti *accuracy*, *precision*, *recall*, dan *f1-score* sebagai evaluasi dari *spam filtering* dengan metode Naïve Bayes. Rincian matriks evaluasi yang digunakan meliputi:

- 1) *Accuracy*, yaitu proporsi prediksi yang benar terhadap total data.
- 2) *Precision*, yaitu proporsi prediksi positif yang benar terhadap total prediksi positif.
- 3) *Recall*, yaitu proporsi data positif yang berhasil diklasifikasikan dengan benar terhadap total data positif.
- 4) *F1-Score*, yaitu rata-rata harmonis dari *precision* dan *recall*.

Matriks ini memberikan gambaran yang komprehensif tentang kinerja model, terutama dalam kasus data yang tidak seimbang

Hasil dan Pembahasan

A. Data Input

Langkah awal dalam proses analisis data adalah mengimpor pustaka-pustaka (*libraries*) yang diperlukan menggunakan python, seperti, *pandas*, *numpy*, dan pustaka dari *sklearn* seperti *TfidfVectorizer* dan *train_test_split*. Dataset dimuat dalam format *.csv* yang selanjutnya akan dilakukan analisis, mulai dari pembersihan data hingga pembuatan model klasifikasi.

B. Preprocessing Data

1. Cleaning

Langkah pertama dalam tahap *preprocessing* data yakni melakukan *cleaning* menggunakan modul *re* (*regular expressions*) untuk membersihkan teks dari karakter non-alfanumerik dan tanda baca. Dengan mengganti pola `r' [^\w\s] '` dengan string kosong (`' '`), teks yang awalnya mengandung tanda baca seperti koma atau titik akan menjadi bersih, menyisakan huruf A-Z, a-z, angka 0-9, garis bawah (`_`), dan spasi (termasuk *tab* dan *newline*).

2. Case folding

Selanjutnya, fungsi `text.lower()` diterapkan pada variabel *text* yang berisi teks setelah proses sebelumnya dengan mengonversi seluruh huruf dalam teks menjadi huruf kecil (*lowercase*) untuk menghindari perbedaan makna di antara kata yang sama dengan huruf besar dan kecil yang berbeda.

3. Tokenizing

Pada tahap tokenisasi, fungsi `word_tokenize` dari *library nltk* memecah teks menjadi unit terkecil yang disebut token berdasarkan spasi dan tanda baca, yang biasanya berupa kata-kata individu, untuk mempersiapkan agar teks bisa dihitung frekuensi katanya atau pun diterapkan algoritma *machine learning*.

4. Stopword removal

Stopword removal digunakan pada kata umum berulang yang tidak memiliki makna penting seperti *di*, *dan*, *yang*, dsb. Hal ini dilakukan untuk mengurangi dimensi data tanpa menghilangkan informasi penting yang terkandung pada data teks.

5. Stemming

Setelah *stopword* dieliminasi, setiap teks akan disamakan berdasarkan akar katanya supaya lebih mudah dipahami dan dianalisis. Pada tahapan ini, setiap imbuhan seperti *di-*, *me-*, *-lah*, dan lainnya akan dihilangkan untuk kemudian akan didapatkan kata dasar setiap teks. Tahap ini bertujuan untuk membuat daftar *tokens* baru dengan kata dasar bahasa Indonesia yang telah dihilangkan imbuhan. Hal ini membuat kata-kata dengan arti yang sama dianggap setara.

Berikut ini merupakan contoh penerapan *preprocessing* data pada pesan teks.

Penerapan pada Pesan Teks	
Sebelum <i>Preprocessing</i>	Setelah <i>Preprocessing</i>
Selamat, Anda lolos Tahap Administrasi seleksi Djarum Beasiswa Plus 2024/2025. Silahkan cek email (Inbox/Spam/Promotion) utk melihat Undangan Tes Tulis Online.	selamat lolos tahap administrasi seleksi djarum beasiswa plus 20242025 silah cek email inboxspampromotion utk undang tes tulis online
Pkt Xtra Combo Mini 6GB, 7hr Anda sudah berakhir. Ayo aktifkan paket menarik lainnya di myXL.	pkt xtra combo mini 6gb 7hr ayo aktif paket tarik myxl
Kirimin alamat yang kemarin dong	Kirimin alamat kemarin
Kamu pelanggan terpilih! Dapatkan voucher Indomaret hingga 500rb dgn transaksi di bima+ sekarang! bima-3.co/HHDS	langgan pilih dapat voucher indomaret 500rb dgn transaksi bima bima3cohhds
HappyPlay 3GB, main game puas dengan pilih benefit MLBB 12 Diamond/FF 24 Diamond/Voucher GooglePlay 5rb hny 15rb/3hr. Beli di bima-3.co/hpg3gb	happyplay 3gb main game puas pilih benefit mlbb 12 diamondff 24 diamondvoucher googleplay 5rb hny 15rb3hr beli bima3cohp3gb

Dapat dilihat terdapat perbedaan antara data teks yang belum dilakukan *preprocessing* dan data teks yang sudah dilakukan *preprocessing*. Pada baris pertama, data yang belum di-*preprocessing* masih memiliki kata berulang seperti “Anda”. Pada baris 998 data sebelum *preprocessing*, masih tercantum teks dengan imbuhan “pelanggan”, sedangkan teks tersebut diubah menjadi “langgan” pada data setelah *preprocessing*.

Tidak lupa, data yang telah melalui tahap *preprocessing* selanjutnya dibagi menjadi dua *subset*, yaitu data latih/*training* sebesar 80% dan data uji/*testing* sebesar 20%. Parameters *stratify* memastikan distribusi label pesan yang dikategorikan sebagai spam atau ham pada data latih dan data uji akan tetap proporsional.

C. Pembobotan dengan TF-IDF

Setelah melakukan *preprocessing* data, selanjutnya dilakukan pembobotan dengan TF-IDF (*Term Frequency-Inverse Document Frequency*). Pada tahap ini, akan dilakukan pembobotan terhadap kata yang akan membantu identifikasi kata yang relevan untuk klasifikasi.

Output Pembobotan TF-IDF	
Data Latih (Training)	Data Uji (Testing)
(0, 4158) 0.2120809	(0, 78) 0.1422654
(0, 1634) 0.2943503	(0, 123) 0.1692257
(0, 1113) 0.1577389	(0, 124) 0.17913423
...	...
(799, 4947) 0.5807895	(199, 4534) 0.1612182

Nilai TF-IDF menggambarkan seberapa penting fitur tertentu (kata atau n-gram) di dalam dokumen tertentu. Nilai TF-IDF yang tinggi menunjukkan bahwa kata tersebut sering muncul di dokumen tertentu tetapi jarang muncul di dokumen lainnya, sedangkan nilai TF-IDF yang rendah menunjukkan bahwa kata tersebut sering muncul di banyak dokumen. Berdasarkan *output* yang dihasilkan, ditunjukkan dokumen, fitur, dan nilai TF-IDF dari fitur atau kata tersebut. Misalnya, pada *output* pembobotan TF-IDF data *training* terdapat *output* (0, 4158) 0.21208091739353216 yang berarti kata atau n-gram ke-4158 pada dokumen ke-0 memiliki bobot 0.212. Kata ini dapat dikatakan cukup signifikan dalam dokumen ke-0, tetapi kemungkinan tidak terlalu umum di seluruh *dataset*.

D. Klasifikasi Naive Bayes

Klasifikasi teks menggunakan algoritma Naïve Bayes, khususnya metode Multinomial Naïve Bayes. Algoritma ini dipilih karena cocok untuk pengolahan data teks yang telah dikonversi menjadi bentuk numerik, seperti matriks TF-IDF. Multinomial Naïve Bayes bekerja dengan asumsi bahwa setiap fitur (kata atau token) bersifat independen terhadap fitur lainnya.

Proses dimulai dengan membangun model klasifikasi menggunakan perintah `MultinomialNB()`. Pada tahap ini, model dibuat tanpa pengetahuan apa pun mengenai pola dalam data karena model belum dilatih. Selanjutnya, model dilatih menggunakan data latih dengan memanggil fungsi `fit`. Proses ini bertujuan agar model dapat mempelajari pola antara fitur teks yang telah direpresentasikan dalam bentuk matriks TF-IDF dan label kategori pada data latih.

Model yang telah dilatih diharapkan mampu mengenali pola pada data teks, sehingga dapat digunakan untuk memprediksi kategori data baru dengan akurasi yang tinggi. Pemilihan algoritma Multinomial Naïve Bayes dinilai tepat karena algoritma ini memiliki kecepatan yang tinggi, sederhana, dan menghasilkan performa yang baik pada tugas klasifikasi teks, terutama untuk *dataset* berukuran besar.

E. Evaluasi

Selanjutnya, dilakukan evaluasi performa model menggunakan *Confusion Matrix*, *Classification Report*, dan *Accuracy Score*. Untuk menampilkan evaluasi tersebut, dibuat `y_pred` terlebih dahulu, yaitu data hasil prediksi dari model untuk data `x_test_tfidf` (data uji yang telah diproses dengan TF-IDF). Setelah itu, evaluasi dilakukan menggunakan `y_pred` dan `y_test`.

Hasil Evaluasi				
Confusion Matrix				
$\begin{bmatrix} 85 & 8 \\ 0 & 107 \end{bmatrix}$				
Classification Report				
	Precision	Recall	F1-Score	Support
Ham	1.00	0.91	0.96	93
spam	0.93	1.00	0.96	107
Macro avg	0.97	0.96	0.96	200
weighted avg	0.96	0.96	0.96	200
Accuracy Score				
0.96				

Berdasarkan hasil di atas, diperoleh hasil evaluasi model menggunakan *confusion matrix*, *classification report*, dan *accuracy score*. Berdasarkan hasil *confusion matrix*, model yang dibuat menghasilkan 85 *True Positive*, 8 *False Positive*, 0 *False Negative*, dan 107 *True Negative*. *True Positive* menunjukkan bahwa terdapat 85 data ham yang diprediksi benar sebagai ham, *false positive* menunjukkan terdapat 8 data ham yang salah diprediksi sebagai spam. *False negative* menunjukkan bahwa terdapat 0 data spam yang salah diprediksi sebagai ham, dan *true negative* menunjukkan bahwa terdapat 107 data spam yang diprediksi benar sebagai spam. Secara keseluruhan, model sudah baik dalam menentukan pesan SMS spam dan ham, walaupun terdapat sedikit kesalahan dalam memprediksi data ham.

Hasil evaluasi menggunakan *classification report* dibagi menjadi *precision*, *recall*, *f1-score*, dan *support*. Nilai *precision* untuk kelas ham diperoleh sebesar 1,00, yang berarti semua prediksi untuk

kelas ham benar tanpa ada kesalahan. Sedangkan untuk kelas *spam*, *precision* yang diperoleh sebesar 0,93, yang menunjukkan bahwa 93% dari prediksi *spam* benar, sementara sisanya salah diklasifikasikan. Dari sisi *recall*, kelas ham memiliki nilai sebesar 0,91, yang berarti 91% data yang sebenarnya ham berhasil dideteksi dengan benar, sedangkan kelas *spam* memiliki nilai *recall* sempurna sebesar 1,00 yang menunjukkan bahwa semua data *spam* terdeteksi dengan benar. Kombinasi dari *precision* dan *recall* dihitung melalui *f1-score* yang untuk kedua kelas bernilai 0,96. Hal ini menunjukkan bahwa model memiliki keseimbangan yang sangat baik antara kemampuan mendeteksi dengan benar (*recall*) dan memastikan prediksi yang dilakukan akurat (*precision*). Nilai *support* digunakan untuk menampilkan banyak data pada evaluasi model. Berdasarkan *support*, jumlah data ham yang digunakan untuk evaluasi adalah sebanyak 93 data dan jumlah data spam yang digunakan adalah sebanyak 107 data sehingga dapat diketahui bahwa total data yang digunakan untuk evaluasi model adalah 200 data. Selain itu, nilai *accuracy score* juga diperoleh sebesar 0,96 atau 96%. Hal ini menunjukkan bahwa dari 200 total data uji yang digunakan, model mampu melakukan *spam filtering* dengan tingkat akurasi sebesar 96%. Dengan demikian, model yang telah dibuat dianggap sudah efektif untuk melakukan *spam filtering* pada SMS.

Setelah mengevaluasi performa model, selanjutnya dilakukan percobaan untuk menguji model menggunakan input manual. Misalnya dibuat contoh pesan atau teks yang dianggap sebagai ham dan spam. Kemudian dilakukan transformasi terhadap teks tersebut menjadi representasi numerik menggunakan model TF-IDF yang telah dilatih sebelumnya dan dilakukan prediksi menggunakan model klasifikasi Naïve Bayes untuk melihat apakah model dapat membedakan pesan spam dan ham sesuai harapan.

Ham Test Prediction: ['ham'] Spam Test Prediction: ['spam']
--

Berdasarkan hasil yang ditampilkan terlihat bahwa model dapat memprediksi pesan atau teks baru sebagai ham dan spam dengan sesuai. Hasil ini dengan kata lain menjadi validasi untuk performa model yang baik pada kasus baru yang mungkin tidak ada di dalam data latih atau data uji.

Kesimpulan

Penelitian menunjukkan bahwa *text mining* berbasis algoritma Naïve Bayes telah berhasil diterapkan untuk *spam filtering* pada pesan SMS. Algoritma ini menunjukkan performa yang sangat baik dalam mengklasifikasikan pesan dari ponsel peneliti dengan mencapai akurasi hingga 96%. Hal ini mengindikasikan bahwa Naïve Bayes dapat secara efektif membedakan pesan *spam* dari pesan biasa (ham), meskipun jumlah *dataset* yang digunakan relatif kecil. Tahapan *preprocessing* data, seperti *cleaning*, *case folding*, *tokenizing*, *stopword removal*, dan *stemming* menjadi langkah krusial dalam meningkatkan kualitas dan kesiapan data yang digunakan untuk klasifikasi. Selain itu, pembobotan menggunakan TF-IDF juga memungkinkan algoritma untuk fokus hanya pada kata-kata yang relevan untuk dianalisis, sehingga meningkatkan akurasi dan efisiensi klasifikasi. Dengan besaran *precision* dan *recall* yang tinggi, model ini menunjukkan keseimbangan yang sangat baik dalam mendeteksi pesan *spam* sekaligus meminimalkan kesalahan prediksi. Nilai *f1-score* sebesar 0,96 mengindikasikan kinerja yang konsisten dan andal. Penelitian ini membuktikan bahwa *text mining* dapat menjadi alat yang andal untuk menyaring pesan SMS dan membantu melindungi pengguna dari gangguan maupun potensi kerugian yang ditimbulkan oleh pesan *spam*.

Daftar Pustaka

- Abdulhamid, S. M., Abd Latiff, M. S., Chiroma, H., Osho, O., Abdul-Salaam, G., Abubakar, A. I., & Herawan, T. (2017). A Review on Mobile SMS Spam Filtering Techniques. *IEEE Access*, 5, 15650–15666. <https://doi.org/10.1109/ACCESS.2017.2666785>
- Anggraini, D. A., Ikhsan, M., & Suhardi, S. (2024). Implementation of the Naïve Bayes Algorithm in the SMS Spam Filtering System. *Journal of Computer Networks, Architecture and High Performance Computing*, 6(2), 841. <https://doi.org/10.47709/cnahpc.v6i2.3875>
- Arif Sofyan, M., Rahaningsih, N., & Danar Dana, R. (2024). Deteksi Sms Spam Berbahasa Indonesia Menggunakan Algoritma Support Vector Machine. *JATI (Jurnal Mahasiswa Teknik Informatika)*, 8(3), 3071–3079. <https://doi.org/10.36040/jati.v8i3.9532>
- Badan Siber dan Sandi Negara RI. (2023). *Laporan Keamanan Siber Indonesia 2023* (Nomor 70, ID-SIRTII Annual Report 2023). <https://idsirtii.or.id/halaman/tentang/laporan-hasil-monitoring.html>
- Banten Jaya, U., Syeh Nawawi Albantani, J., & -Banten, S. (2019). Perbandingan Algoritma Naïve Bayes Dan Support Vector Machine (Svm) Dalam Klasifikasi Sms Spam Berbahasa Indonesia. *SAINTEK (Jurnal Sains & Teknologi)*, 3, 178–193. <https://ejournal.lppm-unbaja.ac.id/index.php/saintek/article/view/662>
- Bukola Asaju, C., Ekorabon, J., & Ojochegebe, R. (2021). Short Message Service (Sms) Spam Detection and Classification Using Naïve Bayes. *International Journal of Mechatronics, Electrical and Computer Technology (IJMEC) (Print)*, 11(40), 4931–4936. <https://aeuso.org>
- Ojugo, A. A., & Oyemade, D. A. (2021). Boyer moore string-match framework for a hybrid short message service spam filtering technique. *IAES International Journal of Artificial Intelligence*, 10(3), 519–527. <https://doi.org/10.11591/ijai.v10.i3.pp519-527>
- Ramdhan, D., Lucky, H., Kemala, A. P., & Chowanda, A. (2022). SHORT MESSAGE SERVICE (SMS) SPAM FILTERING USING DEEP LEARNING IN BAHASA INDONESIA. *ICIC Express Letters, Part B: Applications*, 13(10), 1093–1100. <https://doi.org/10.24507/icicelb.13.10.1093>
- Roufia, A. (2018). *Text Mining Dengan Metode Naïve Bayes Classifier Untuk Mengklasifikan Berita Berdasarkan Konten* [Institut Teknologi Sepuluh Nopember]. <http://repository.its.ac.id/id/eprint/51007>
- Triawati, C. (2009). Metode Pembobotan Statistical Concept Based untuk Klastering dan Kategorisasi Dokumen Berbahasa Indonesia Statistical Concept Based Weighting Method for Indonesian Language Document Clustering and Categorisation. *Jurnal Informatika*, 5, 90. <https://openlibrary.telkomuniversity.ac.id/pustaka/94970/metode-pembobotan-statistical-concept-based-untuk-klastering-dan-kategorisasi-dokumen-berbahasa-indonesia-statistical-concept-based-weighting-method-for-indonesian-language-document-clustering-and-categorisation>
- W, Ebranda A, Novi Triana, Mardiani S.Si, M.T.I, Tinaliah, S. ko. (2013). Penerapan Metode Naïve Bayes Untuk Sistem Klasifikasi Sms Pada Smartphone Android. *Penerapan Metode Naïve Bayes Untuk Sistem Klasifikasi Sms Pada Smartphone Android*, 1–8. SMS Spam, Android, Naïve Bayes, dan eclipse.
- Wahid, A., Baharulloh, M., Kahfiansyah, R., Abrilianto, T., Saifudin, A., & Mulyati, S. (2021). Identifikasi SMS Spam Menggunakan Metode Naive Bayes. *Informatika Universitas Pamulang*, 6(3), 536–537. <http://openjournal.unpam.ac.id/index.php/informatika536>